

# **PRESENTAZIONE PROGETTO MACHINE LEARNING**

**DINO MENG [SM3201466]**

# Argomenti:

1. Idea del clustering spettrale, richiami su SVD
2. Algoritmo di clustering spettrale e variante basata su SVD
3. Esperimenti


# SVD (Richiami)

La *SVD* (Singular-Value Decomposition) è una tecnica nota di decomposizione di matrici basata sulla decomposizione spettrale

$$A = U\Sigma V^T$$


Applicazioni:

- "Low-Rank Matrix Approximation"  
(Teorema di Eckart–Young)
- Compressione delle immagini
- Riduzione della dimensionalità
- **Vedremo:** Clustering



# Clustering spettrale (Formulazione del Problema)

**Problema:** Determinare un  $k$ -partizionamento del grafo  $G = (V, E)$ , minimizzando i tagli da effettuare



# Clustering spettrale

## Unnormalized spectral clustering

Input: Similarity matrix  $S \in \mathbb{R}^{n \times n}$ , number  $k$  of clusters to construct.


- Construct a similarity graph by one of the ways described in Sect. 2. Let  $W$  be its weighted adjacency matrix.
- Compute the unnormalized Laplacian  $L$ .
- **Compute the first  $k$  eigenvectors  $u_1, \dots, u_k$  of  $L$ .**
- Let  $U \in \mathbb{R}^{n \times k}$  be the matrix containing the vectors  $u_1, \dots, u_k$  as columns.
- For  $i = 1, \dots, n$ , let  $y_i \in \mathbb{R}^k$  be the vector corresponding to the  $i$ -th row of  $U$ .
- Cluster the points  $(y_i)_{i=1, \dots, n}$  in  $\mathbb{R}^k$  with the  $k$ -means algorithm into clusters  $C_1, \dots, C_k$ .

Output: Clusters  $A_1, \dots, A_k$  with  
 $A_i = \{j | y_j \in C_i\}.$

Tratto da: Ulrike von Luxburg, *A Tutorial on Spectral Clustering*

# Clustering spettrale (Osservazione)

Osservazione: si dimostra che l'algoritmo descritto in precedenza risolve un opportuno rilassamento del problema dei minimi  $k$ -cut del grafo  $G$



## Clustering spettrale basato su SVD (Idea)

**IDEA.** Invece di trovare gli autovalori del Laplaciano  $L = D - A$ , diagonalizzare le matrici  $A^T A$  e  $AA^T$  (determinando così una SVD di  $A$ )

Variante proposta da Zhixian Jia, nell'articolo "The reaserch on parameters of spectral clustering based on SVD" (2013)

# Clustering spettrale basato su SVD

Parametri:

- Numero di cluster  $k$
- Numero di vettori singolari sinistri da considerare  $l$  (di solito  $l = k$ )

Algoritmo:

1. Creare la matrice di somiglianza  $A$  con un metodo a piacere
2. Determinare una SVD di  $A$ , cioè  $A = V\Sigma U^T$
3. Prendere le prime  $l$  colonne di  $V$ , e denotarle con  $V'$
4. Eseguire *k-means* su  $V'$ , i cluster risultanti costituiscono l'output




# Esperimenti: Introduzione, obiettivi

Tre esperimenti principali, basati su dataset generati sinteticamente:


1. Confrontare il clustering spettrale e la sua variante basata sulla SVD. Due metodi di costruzione del grafo  $(V, E) \sim A$ : kernel gaussiano (grafo pesato e completamente connesso) e KNN-graph.
2. Eseguire la *SVD-based Spectral Clustering* su dataset non lineari (variando i parametri)
3. Dedurre il parametro  $k$  dallo studio della matrice dei valori singolari  $\Sigma$

# Dataset sintetici

Example Dataset (1.1)





Example Dataset (1.2)




# Dataset sintetici

Non Linearly-separable Datasets




# Dataset sintetici




# Esperimento 1.1

Costruzione del grafo: Si usa il kernel gaussiano  $s(x, y) = \exp -(\|x - y\|_2^2 / (2\sigma)^2)$  con  $\sigma = 1.7$



# Esperimento 1.2

Costruzione del grafo: KNN-embedding. Per lo SC classico,  $k = 60$ ; per lo SC basato su SVD,  $k = 15$ .




## Esperimento 2

**Costruzione del Grafo:** Per i due cerchi abbiamo usato la stessa dell'Esperimento 1. Per il dataset delle mezzelune, abbiamo utilizzato il KNN-graph per rappresentare il grafo

**Parametri:** Per il dataset dei due cerchi abbiamo variato l'iperparametro  $l$  con  $l = 1$ ,  $l = 2$ . Per il dataset delle due mezzelune,  $k = 5, 15$



## Esperimento 2 (Risultati)





# Esperimento 2 (Risultati)

SVD-Based Spectral Clustering with KNN-Graph Adjacency



## Esperimento 3: deduzione dei parametri

- Per la costruzione del grafo, useremo il kernel gaussiano parametrizzato in  $\sigma > 0$ :

$$s(x, y) = \exp(-\|x - y\|_2^2 / 2\sigma^2)$$

- Supponiamo di non conoscere nè  $k$  nè  $\sigma$ : come possiamo determinare tali parametri?
- Le seguenti formule ci potranno "*suggerire*" tali parametri. Dati  $(\sigma_i)_i$  tratti da  $\Sigma$ ,



$$(1) \sigma_k - \sigma_{k+1}$$

$$(2) \sigma_k - 2\sigma_{k+1} + \sigma_{k+2}$$

$$(3) \frac{\sum_{i \leq k} \sigma_i}{\sum_{i \leq N} \sigma_i} \geq \theta$$



# Esperimento 3: analisi

Deduced  $k$  values for sigma = 1



# Esperimento 3: analisi

Deduced  $k$  values for sigma = 2



# Esperimento 3: risultati

Abbiamo quindi dedotto le variabili  $k = 3$  e  $\sigma = 2$

